

Proyecto 2: Auditoría de ventas en una joyería usando diamonds

Isaac Alexander Morales Arévalo

2026-05-12

Una empresa dedicada a la venta de joyas desea analizar su inventario de diamantes. El equipo comercial sospecha que algunos diamantes tienen precios inusualmente altos en relación con su peso, por lo que necesita construir un reporte que permita identificar productos costosos, calcular indicadores de precio y resumir la información por calidad de corte.

Base de datos

Para este proyecto se utilizará la base de datos diamonds, incluida en el paquete ggplot2. Esta base contiene información sobre diamantes y algunas de sus características físicas y comerciales.

Descripción de las columnas

La base de datos diamonds contiene las siguientes variables:

- price: precio del diamante en dólares.
 - carat: peso del diamante en quilates.
 - cut: calidad del corte (Fair, Good, Very Good, Premium, Ideal).
 - color: calidad del color del diamante.
 - clarity: nivel de imperfecciones del diamante.
 - x: longitud en milímetros.
 - y: ancho en milímetros.
 - z: profundidad en milímetros.
 - depth: porcentaje de profundidad total.
 - table: ancho superior del diamante en porcentaje.
-

Problema

La empresa desea construir un reporte que permita estudiar qué tipos de diamantes presentan precios relativamente altos en comparación con su peso.

Para ello, se busca responder:

- ¿Qué tipos de corte tienen mayor precio promedio?
 - ¿Qué tipos de corte presentan mayor precio por quilate?
 - ¿Cuántos diamantes aparecen clasificados como productos de precio muy alto?
-

Indicaciones

El análisis debe realizarse en un documento R Markdown, combinando texto, código en R y resultados.

Se utilizarán tuberías (%>%) y funciones de manipulación de datos del paquete dplyr.

1. Introducción

Este análisis tiene como objetivo evaluar el comportamiento del precio de los diamantes considerando su peso, con el fin de detectar productos relativamente costosos.

2. Exploración de Datos

```
head(diamonds)
```

```
## # A tibble: 6 x 10
##   carat cut      color clarity depth table price     x     y     z
##   <dbl> <ord>    <ord> <ord>    <dbl> <dbl> <int> <dbl> <dbl> <dbl>
## 1  0.23 Ideal    E     SI2     61.5    55   326   3.95   3.98   2.43
## 2  0.21 Premium  E     SI1     59.8    61   326   3.89   3.84   2.31
## 3  0.23 Good     E     VS1     56.9    65   327   4.05   4.07   2.31
## 4  0.29 Premium  I     VS2     62.4    58   334   4.2    4.23   2.63
## 5  0.31 Good     J     SI2     63.3    58   335   4.34   4.35   2.75
## 6  0.24 Very Good J     VVS2     62.8    57   336   3.94   3.96   2.48
```

```
str(diamonds)
```

```
## tibble [53,940 x 10] (S3: tbl_df/tbl/data.frame)
##  $ carat   : num [1:53940] 0.23 0.21 0.23 0.29 0.31 0.24 0.24 0.26 0.22 0.23 ...
##  $ cut      : Ord.factor w/ 5 levels "Fair"<"Good"<...: 5 4 2 4 2 3 3 3 1 3 ...
##  $ color    : Ord.factor w/ 7 levels "D"<"E"<"F"<"G"<...: 2 2 2 6 7 7 6 5 2 5 ...
```

```
## $ clarity: Ord.factor w/ 8 levels "I1"<"SI2"<"SI1"<...: 2 3 5 4 2 6 7 3 4 5 ...
## $ depth  : num [1:53940] 61.5 59.8 56.9 62.4 63.3 62.8 62.3 61.9 65.1 59.4 ...
## $ table   : num [1:53940] 55 61 65 58 58 57 57 55 61 61 ...
## $ price   : int [1:53940] 326 326 327 334 335 336 336 337 337 338 ...
## $ x       : num [1:53940] 3.95 3.89 4.05 4.2 4.34 3.94 3.95 4.07 3.87 4 ...
## $ y       : num [1:53940] 3.98 3.84 4.07 4.23 4.35 3.96 3.98 4.11 3.78 4.05 ...
## $ z       : num [1:53940] 2.43 2.31 2.31 2.63 2.75 2.48 2.47 2.53 2.49 2.39 ...
```

3. Justificación

El precio total no es suficiente para comparar diamantes, ya que los más grandes tienden a ser más caros. Por ello se utiliza el precio relativo (precio por quilate).

4. Construcción de la variable

```
diamonds2 <- diamonds %>%
  mutate(precio_carat = price / carat)
```

5. Clasificación

```
#Definimos los cuantiles q1 y q2

q1 <- quantile(diamonds2$precio_carat,0.25)
q3 <- quantile(diamonds2$precio_carat, 0.75)

diamonds2 <- diamonds2 %>%
  mutate(
    clasificacion = case_when( precio_carat > q3 ~ "Alto",
                              precio_carat < q1 ~ "Bajo",
                              TRUE ~ "Medio"))
```

Interpretación de la clasificación

La clasificación de los diamantes en “Alto”, “Medio” y “Bajo” se realizó utilizando cuantiles (25% y 75%) del precio por quilate.

Se eligieron estos puntos de corte porque:

- Permiten dividir los datos de forma objetiva según su distribución.
- Identifican el 25% de los diamantes más baratos (“Bajo”) y el 25% más caros (“Alto”).

- Evitan el uso de valores arbitrarios, haciendo el análisis más consistente.

De esta forma, los diamantes clasificados como “Alto” corresponden a aquellos con precios por quilate significativamente superiores al promedio general, lo cual es útil para detectar productos potencialmente sobrevalorados.

6. Inspección Intermedia

```
diamonds2 %>%  
  group_by(clasificacion) %>%  
  summarise( cantidad = n(), promedio_precio_carat = mean(precio_carat) )
```

```
## # A tibble: 3 x 3  
##   clasificacion cantidad promedio_precio_carat  
##   <chr>          <int>          <dbl>  
## 1 Alto           13485           6877.  
## 2 Bajo           13485           1998.  
## 3 Medio          26970           3579.
```

7. Analisis de corte

#Precio promedio

```
diamonds2 %>%  
  group_by(cut) %>%  
  summarise(precio_promedio = mean(price))
```

```
## # A tibble: 5 x 2  
##   cut      precio_promedio  
##   <ord>          <dbl>  
## 1 Fair           4359.  
## 2 Good           3929.  
## 3 Very Good     3982.  
## 4 Premium       4584.  
## 5 Ideal          3458.
```

#Precio por quilate

```
diamonds2 %>%  
  group_by(cut) %>%  
  summarise(precio_carat_promedio = mean(precio_carat))
```

```
## # A tibble: 5 x 2
##   cut      precio_carat_promedio
##   <ord>          <dbl>
## 1 Fair          3767.
## 2 Good          3860.
## 3 Very Good     4014.
## 4 Premium       4223.
## 5 Ideal         3920.
```


#Cantidad de diamantes con precio alto

```
diamonds2 %>%
  filter(clasificacion == "Alto") %>%
  group_by(cut) %>%
  summarise(cantidad = n())
```

```
## # A tibble: 5 x 2
##   cut      cantidad
##   <ord>          <int>
## 1 Fair          298
## 2 Good         1101
## 3 Very Good     3134
## 4 Premium       4039
## 5 Ideal         4913
```

8. Visualización de los Datos

```
ggplot(diamonds2, aes(x = cut, y = precio_carat)) + geom_boxplot()
```



Interpretación del diagrama de caja

El diagrama de caja muestra la distribución del precio por quilate (`precio_carat`) para cada tipo de corte del diamante.

En cada categoría de corte se observa:

- La línea central de la caja representa la **mediana** del precio por quilate.
- Los bordes de la caja corresponden al **rango intercuartílico (Q1 y Q3)**.
- Los puntos que aparecen por encima de las cajas representan **valores atípicos (outliers)**, es decir, diamantes con precios por quilate inusualmente altos.

Se puede notar que algunos tipos de corte presentan mayor dispersión en los precios, así como una mayor cantidad de valores extremos, lo que indica variabilidad en el valor de los diamantes dentro de esa categoría.

9. Conclusiones

- Existen diferencias en el precio promedio según el tipo de corte.
- El precio por quilate permite una comparación más justa entre diamantes.
- Se logró clasificar los diamantes en categorías de precio relativo.
- Algunos cortes concentran una mayor cantidad de diamantes con precios elevados.