

Proyecto 2: Auditoría automatizada de bases de datos para reportes empresariales

Isaac Alexander Morales Arévalo

2026-06-15

Introducción y contexto del problema.

En una empresa de análisis de datos es común recibir varias bases de datos provenientes de distintas áreas: ventas, transporte, producción, inventarios o estudios técnicos.

Antes de hacer análisis avanzados, es necesario revisar la calidad de cada base de datos. Por ejemplo:

- identificar qué columnas son numéricas;
- detectar valores faltantes;
- calcular medidas resumen;
- revisar si hay columnas con poca variabilidad;
- encontrar posibles errores;
- comparar variables entre sí;
- generar reportes automáticos.

En este proyecto se construirá un sistema sencillo de auditoría de datos usando únicamente herramientas de iteración en R.

Bases de datos a utilizar

Usaremos bases de datos conocidas que vienen incluidas en R:

```
data(mtcars)
data(cars)
data(iris)
data(airquality)
```

Descripción breve de las bases

mtcars

Contiene información de automóviles, como consumo de combustible, peso, potencia y número de cilindros.

cars

Contiene información sobre velocidad y distancia de frenado de automóviles.

iris

Contiene mediciones de flores de tres especies distintas.

airquality

Contiene mediciones de calidad del aire en Nueva York, incluyendo ozono, radiación solar, viento y temperatura.

Cargando librerías:

```
library(purrr)
library(dplyr)
```

```
## Warning: package 'dplyr' was built under R version 4.4.3
```

```
##
```

```
## Adjuntando el paquete: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
```

```
##
```

```
##      filter, lag
```

```
## The following objects are masked from 'package:base':
```

```
##
```

```
##      intersect, setdiff, setequal, union
```

```
library(tibble)
```

Enlistando nuestra base de datos:

```
bases <- list(
  mtcars = mtcars,
  cars = cars,
  iris = iris,
  airquality = airquality
)
```

Calculando las dimensiones y estructura:

```
map(bases, nrow)  # filas
```

```
## $mtcars
```

```
## [1] 32
```

```
##
```

```
## $cars
```

```
## [1] 50
```

```
##
```

```
## $iris
## [1] 150
##
## $airquality
## [1] 153
```

```
map(bases, ncol) # columnas
```

```
## $mtcars
## [1] 11
##
## $cars
## [1] 2
##
## $iris
## [1] 5
##
## $airquality
## [1] 6
```

```
map(bases, class) # clase del objeto
```

```
## $mtcars
## [1] "data.frame"
##
## $cars
## [1] "data.frame"
##
## $iris
## [1] "data.frame"
##
## $airquality
## [1] "data.frame"
```

Auditoria de tipos de variables.

```
auditoria_tipos <- map(bases, function(df){

  num_cols <- sum(map_lgl(df, is.numeric))
  total_cols <- ncol(df)

  tibble(
    columnas_numericas = num_cols,
    columnas_no_numericas = total_cols - num_cols,
    todas_numericas = num_cols == total_cols,
    existe_no_numerica = num_cols < total_cols
  )
})

auditoria_tipos
```

```
## $mtcars
## # A tibble: 1 x 4
##   columnas_numericas columnas_no_numericas todas_numericas existe_no_numerica
##             <int>             <int> <lgl>             <lgl>
## 1             11             0 TRUE             FALSE
##
## $cars
## # A tibble: 1 x 4
##   columnas_numericas columnas_no_numericas todas_numericas existe_no_numerica
##             <int>             <int> <lgl>             <lgl>
## 1             2             0 TRUE             FALSE
##
## $iris
## # A tibble: 1 x 4
##   columnas_numericas columnas_no_numericas todas_numericas existe_no_numerica
##             <int>             <int> <lgl>             <lgl>
## 1             4             1 FALSE             TRUE
##
## $airquality
## # A tibble: 1 x 4
##   columnas_numericas columnas_no_numericas todas_numericas existe_no_numerica
##             <int>             <int> <lgl>             <lgl>
## 1             6             0 TRUE             FALSE
```

Reporte de Columnas numéricas.

```
resumen_numerico <- map(bases, function(df){

  df_num <- select(df, where(is.numeric))

  map_dfr(df_num, function(col){

    tibble(
      media = mean(col, na.rm = TRUE),
      mediana = median(col, na.rm = TRUE),
      sd = sd(col, na.rm = TRUE),
      minimo = min(col, na.rm = TRUE),
      maximo = max(col, na.rm = TRUE),
      rango = diff(range(col, na.rm = TRUE))
    )

  }, .id = "variable")
})

resumen_numerico
```

```
## $mtcars
## # A tibble: 11 x 7
##   variable  media mediana      sd minimo maximo  rango
##   <chr>    <dbl>  <dbl>  <dbl> <dbl>  <dbl> <dbl>
## 1 mpg     20.1    19.2   6.03  10.4   33.9   23.5
## 2 cyl      6.19     6     1.79   4      8      4
```

```
## 3 disp      231.      196.    124.      71.1  472    401.
## 4 hp        147.      123      68.6    52     335    283
## 5 drat       3.60      3.70    0.535    2.76    4.93    2.17
## 6 wt         3.22      3.32    0.978    1.51    5.42    3.91
## 7 qsec       17.8      17.7    1.79    14.5    22.9    8.4
## 8 vs         0.438     0       0.504     0       1       1
## 9 am         0.406     0       0.499     0       1       1
## 10 gear      3.69      4       0.738     3       5       2
## 11 carb      2.81      2       1.62     1       8       7
##
## $cars
## # A tibble: 2 x 7
##   variable media mediana    sd minimo maximo rango
##   <chr>    <dbl>   <dbl> <dbl>  <dbl>  <dbl> <dbl>
## 1 speed    15.4     15  5.29     4     25    21
## 2 dist     43.0     36 25.8     2    120   118
##
## $iris
## # A tibble: 4 x 7
##   variable      media mediana    sd minimo maximo rango
##   <chr>        <dbl>   <dbl> <dbl>  <dbl>  <dbl> <dbl>
## 1 Sepal.Length  5.84     5.8  0.828    4.3     7.9    3.6
## 2 Sepal.Width   3.06      3    0.436     2     4.4    2.4
## 3 Petal.Length  3.76     4.35  1.77     1     6.9    5.9
## 4 Petal.Width   1.20      1.3  0.762    0.1     2.5    2.4
##
## $airquality
## # A tibble: 6 x 7
##   variable      media mediana    sd minimo maximo rango
##   <chr>        <dbl>   <dbl> <dbl>  <dbl>  <dbl> <dbl>
## 1 Ozone       42.1     31.5 33.0     1    168   167
## 2 Solar.R    186.     205  90.1     7    334   327
## 3 Wind        9.96      9.7  3.52     1.7   20.7   19
## 4 Temp       77.9      79   9.47    56     97   41
## 5 Month        6.99      7    1.42     5      9    4
## 6 Day        15.8     16   8.86     1     31   30
```

Manejo de Errores.

Creando una función segura:

```
media_segura <- function(x){
  tryCatch(
    mean(x, na.rm = TRUE),
    error = function(e) NA
  )
}
```

Aplicando dicha función a todas las columnas:

```
medias_seguras <- map(bases, function(df){
  map_dfr(df, function(col){
    tibble(media = media_segura(col))
  })
})
```

```
  }, .id = "variable")
})
```

```
## Warning in mean.default(x, na.rm = TRUE): argument is not numeric or logical:
## returning NA
```

```
medias_seguras
```

```
## $mtcars
## # A tibble: 11 x 2
##   variable  media
##   <chr>    <dbl>
## 1 mpg      20.1
## 2 cyl       6.19
## 3 disp     231.
## 4 hp      147.
## 5 drat       3.60
## 6 wt         3.22
## 7 qsec      17.8
## 8 vs         0.438
## 9 am         0.406
## 10 gear      3.69
## 11 carb      2.81
##
## $cars
## # A tibble: 2 x 2
##   variable media
##   <chr>    <dbl>
## 1 speed     15.4
## 2 dist      43.0
##
## $iris
## # A tibble: 5 x 2
##   variable  media
##   <chr>    <dbl>
## 1 Sepal.Length  5.84
## 2 Sepal.Width   3.06
## 3 Petal.Length  3.76
## 4 Petal.Width   1.20
## 5 Species       NA
##
## $airquality
## # A tibble: 6 x 2
##   variable  media
##   <chr>    <dbl>
## 1 Ozone     42.1
## 2 Solar.R  186.
## 3 Wind       9.96
## 4 Temp      77.9
## 5 Month      6.99
## 6 Day       15.8
```

Comparando entre pares de variables.

Creando una tabla de comparaciones:

```
comparaciones <- tibble(
  base = c("cars", "iris", "iris", "mtcars", "airquality"),
  variable_1 = c("dist", "Petal.Length", "Petal.Width", "hp", "Temp"),
  variable_2 = c("speed", "Sepal.Length", "Sepal.Width", "mpg", "Wind")
)
```

Calculo de comparaciones:

```
resultados_comp <- pmap_dfr(comparaciones, function(base, variable_1, variable_2){

  df <- bases[[base]]

  x1 <- df[[variable_1]]
  x2 <- df[[variable_2]]

  tibble(
    base = base,
    var1 = variable_1,
    var2 = variable_2,
    diff_medias = mean(x1, na.rm = TRUE) - mean(x2, na.rm = TRUE), # Diferencia de medias
    razon_rangos = diff(range(x1, na.rm = TRUE)) / diff(range(x2, na.rm = TRUE)) #Razón de rangos
  )
})

resultados_comp
```

```
## # A tibble: 5 x 5
##   base      var1      var2      diff_medias razon_rangos
##   <chr>    <chr>    <chr>          <dbl>        <dbl>
## 1 cars      dist      speed          27.6          5.62
## 2 iris      Petal.Length Sepal.Length  -2.09          1.64
## 3 iris      Petal.Width  Sepal.Width   -1.86           1
## 4 mtcars    hp          mpg          127.          12.0
## 5 airquality Temp       Wind          67.9          2.16
```

Reporte final con reduce

```
dimensiones <- map_dfr(names(bases), function(nombre){
  df <- bases[[nombre]]
  tibble(
    base = nombre,
    filas = nrow(df),
    columnas = ncol(df)
  )
})
```

Encontrando los valores faltantes

```
faltantes <- map_dfr(names(bases), function(nombre){
  df <- bases[[nombre]]
  tibble(
    base = nombre,
    NA_total = sum(is.na(df))
  )
})
```

Tipos de variables

```
tipos <- map_dfr(names(bases), function(nombre){
  df <- bases[[nombre]]
  num <- sum(map_lgl(df, is.numeric))

  tibble(
    base = nombre,
    num_numericas = num,
    num_no_numericas = ncol(df) - num
  )
})
```

Reduciendo todo

```
reporte_final <- reduce(
  list(dimensiones, faltantes, tipos),
  full_join,
  by = "base"
)

reporte_final
```

```
## # A tibble: 4 x 6
##   base      filas columnas NA_total num_numericas num_no_numericas
##   <chr>    <int>   <int>   <int>         <int>         <int>
## 1 mtcars     32     11      0           11            0
## 2 cars       50      2      0            2            0
## 3 iris      150      5      0            4            1
## 4 airquality 153      6     44            6            0
```

Preguntas de Interpretación

```
# 1. Base con más NA
faltantes %>% arrange(desc(NA_total))
```

```
## # A tibble: 4 x 2
##   base      NA_total
##   <chr>    <int>
## 1 airquality     44
## 2 mtcars          0
## 3 cars            0
## 4 iris            0
```


2. Más columnas numéricas

```
tipos %>% arrange(desc(num_numericas))
```

```
## # A tibble: 4 x 3
##   base      num_numericas num_no_numericas
##   <chr>          <int>          <int>
## 1 mtcars          11              0
## 2 airquality      6              0
## 3 iris            4              1
## 4 cars            2              0
```

3. Variable con mayor rango (ver resumen numerico)

```
rangos_totales <- map_dfr(names(resumen_numerico), function(nombre){
  resumen_numerico[[nombre]] %>%
    mutate(base = nombre)
})

mayor_rango <- rangos_totales %>%
  select(base, variable, rango) %>%
  slice_max(rango, n = 1)

cat(
  "La variable con mayor rango es",
  mayor_rango$variable,
  "de la base",
  mayor_rango$base,
  "con un rango de",
  mayor_rango$rango
)
```

```
## La variable con mayor rango es disp de la base mtcars con un rango de 400.9
```

4. Bases totalmente numéricas

```
auditoria_tipos
```

```
## $mtcars
## # A tibble: 1 x 4
##   columnas_numericas columnas_no_numericas todas_numericas existe_no_numerica
##   <int>                <int> <lgl>                <lgl>
## 1          11              0 TRUE                FALSE
##
## $cars
## # A tibble: 1 x 4
##   columnas_numericas columnas_no_numericas todas_numericas existe_no_numerica
##   <int>                <int> <lgl>                <lgl>
## 1           2              0 TRUE                FALSE
##
## $iris
## # A tibble: 1 x 4
```

```
##   columnas_numericas columnas_no_numericas todas_numericas existe_no_numerica
##           <int>                <int> <lgl>           <lgl>
## 1                4                1 FALSE           TRUE
##
## $airquality
## # A tibble: 1 x 4
##   columnas_numericas columnas_no_numericas todas_numericas existe_no_numerica
##           <int>                <int> <lgl>           <lgl>
## 1                6                0 TRUE            FALSE
```

```
# 5. Mayor diferencia de medias
resultados_comp %>% arrange(desc(abs(diff_medias)))
```

```
## # A tibble: 5 x 5
##   base      var1      var2      diff_medias razon_rangos
##   <chr>    <chr>    <chr>      <dbl>      <dbl>
## 1 mtcars   hp        mpg        127.        12.0
## 2 airquality Temp      Wind        67.9        2.16
## 3 cars     dist      speed       27.6        5.62
## 4 iris     Petal.Length Sepal.Length -2.09        1.64
## 5 iris     Petal.Width  Sepal.Width -1.86         1
```

Conclusiones finales

Este sistema simula una auditoría real de datos empresariales, permitiendo:

- Detectar estructura de bases.
- Identificar calidad de datos.
- Resumir variables numéricas.
- Comparar variables clave.
- Integración de reportes automáticos.

Esto es la base para pipelines reales de data engineering y análisis exploratorio en empresas.