

Tarea #1

Isaac Alexander Morales Arévalo

Tarea: Tuberías con `magrittr`

Indicaciones generales

En esta tarea practicarás el uso del operador tubería `%>%`, del paquete `magrittr`, junto con algunas funciones de `dplyr`.

La idea principal es escribir secuencias de operaciones de forma clara, leyendo el código de arriba hacia abajo.

Antes de iniciar, carga los paquetes:

```
library(magrittr)
library(dplyr)
```

```
## Warning: package 'dplyr' was built under R version 4.4.3
```

```
##
```

```
## Adjuntando el paquete: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
```

```
##
```

```
##      filter, lag
```

```
## The following objects are masked from 'package:base':
```

```
##
```

```
##      intersect, setdiff, setequal, union
```

Ejercicio 1

Usa la base de datos `iris`.

Haz lo siguiente:

1. Conserva únicamente las columnas `Species`, `Sepal.Length`, `Sepal.Width`, `Petal.Length` y `Petal.Width`.
2. Crea una columna llamada `area_sepalo`, definida como `Sepal.Length * Sepal.Width`.
3. Crea una columna llamada `area_petal`, definida como `Petal.Length * Petal.Width`.
4. Crea una columna llamada `razon_areas`, definida como `area_petal / area_sepalo`.
5. Imprime una vista rápida del resultado intermedio.
6. Conserva únicamente las flores cuya `razon_areas` sea mayor que 0.15.

7. Calcula, para cada especie:
 - el promedio de `area_sepalo`,
 - el promedio de `area_petalo`,
 - el promedio de `razon_areas`,
 - la cantidad de flores conservadas.
8. Ordena el resultado de mayor a menor según el promedio de `razon_areas`.

```
library(dplyr)
library(magrittr)

library(dplyr)
library(magrittr)

resultado_iris <- iris %>%
  select(Species, Sepal.Length, Sepal.Width,
         Petal.Length, Petal.Width) %>%
  mutate(
    area_sepalo = Sepal.Length * Sepal.Width,
    area_petalo = Petal.Length * Petal.Width,
    razon_areas = area_petalo / area_sepalo
  ) %>%
  {
    print(head(.))
  } %>%

  filter(razon_areas > 0.15) %>%

  group_by(Species) %>%

  summarise(
    promedio_area_sepalo = mean(area_sepalo),
    promedio_area_petalo = mean(area_petalo),
    promedio_razon_areas = mean(razon_areas),
    cantidad_flores = n()
  ) %>%

  arrange(desc(promedio_razon_areas))
```

```
##   Species Sepal.Length Sepal.Width Petal.Length Petal.Width area_sepalo
## 1  setosa         5.1         3.5         1.4         0.2         17.85
## 2  setosa         4.9         3.0         1.4         0.2         14.70
## 3  setosa         4.7         3.2         1.3         0.2         15.04
## 4  setosa         4.6         3.1         1.5         0.2         14.26
## 5  setosa         5.0         3.6         1.4         0.2         18.00
## 6  setosa         5.4         3.9         1.7         0.4         21.06
##   area_petalo razon_areas
## 1         0.28 0.01568627
## 2         0.28 0.01904762
## 3         0.26 0.01728723
## 4         0.30 0.02103787
## 5         0.28 0.01555556
## 6         0.68 0.03228870
```

Ejercicio 2

Usa la base de datos `mtcars`.

Haz lo siguiente:

1. Conserva únicamente las columnas `mpg`, `hp`, `wt`, `cyl` y `gear`.
2. Conserva únicamente los automóviles con potencia mayor que 100.
3. Crea una columna llamada `rendimiento`, definida como `mpg / hp`.
4. Crea una columna llamada `peso_por_potencia`, definida como `wt / hp`.
5. Imprime las primeras filas del resultado intermedio...
6. Ordena los automóviles de mayor a menor rendimiento.
7. Conserva únicamente los primeros 8 resultados.
8. Calcula la correlación entre `rendimiento` y `peso_por_potencia`.

```
library(dplyr)
library(magrittr)

resultados_mtcars <- mtcars %>%
  select(mpg, hp, wt, cyl, gear) %>%
  filter(hp > 100) %>%
  mutate(
    rendimiento = mpg / hp,
    peso_por_potencia = wt / hp
  ) %>%
  {print(head(.))} %>%
  arrange(desc(rendimiento)) %>%
  slice(1:8) %>%
  summarise(
    correlacion = cor(rendimiento, peso_por_potencia))
```

```
##           mpg  hp   wt  cyl gear rendimiento peso_por_potencia
## Mazda RX4      21.0 110 2.620   6   4  0.19090909      0.02381818
## Mazda RX4 Wag  21.0 110 2.875   6   4  0.19090909      0.02613636
## Hornet 4 Drive  21.4 110 3.215   6   3  0.19454545      0.02922727
## Hornet Sportabout 18.7 175 3.440   8   3  0.10685714      0.01965714
## Valiant        18.1 105 3.460   6   3  0.17238095      0.03295238
## Duster 360     14.3 245 3.570   8   3  0.05836735      0.01457143
```

```
resultados_mtcars
```

```
## correlacion
## 1 -0.8417635
```

Ejercicio 3

Usa la base de datos `airquality`.

En este ejercicio debes usar una tubería, pero también debes decidir en qué momento conviene guardar un objeto intermedio.

Haz lo siguiente:

1. Conserva únicamente las columnas `Ozone`, `Solar.R`, `Wind`, `Temp` y `Month`.
2. Elimina las filas con valores faltantes.
3. Crea una columna llamada `Temp_C`, que convierta la temperatura de Fahrenheit a Celsius:

$$Temp_C = \frac{5}{9}(Temp - 32)$$

4. Crea una columna llamada `dia_caluroso`, que tome el valor "Sí" si `Temp > 85` y "No" en caso contrario.
5. Guarda este resultado en un objeto llamado `aire_limpio`.
6. Usando `aire_limpio`, calcula el promedio de `Ozone`, `Solar.R`, `Wind` y `Temp_C` para cada mes.
7. Ordena el resultado de mayor a menor según el promedio de `Ozone`.

```
library(dplyr)

aire_limpio <- airquality %>%
  select(Ozone, Solar.R, Wind, Temp, Month) %>%
  na.omit() %>%
  mutate(Temp_C = (5/9) * (Temp - 32)) %>%
  mutate(dia_caluroso = ifelse(Temp > 85, "Si", "No"))
resultado_air <- aire_limpio %>%

  group_by(Month) %>%

  summarise(
    promedio_Ozone = mean(Ozone), promedio_SolarR = mean(Solar.R), promedio_Wind = mean(Wind), promedio_TempC = mean(Temp_C),
    arrange(desc(promedio_Ozone))

resultado_air
```

```
## # A tibble: 5 x 5
##   Month promedio_Ozone promedio_SolarR promedio_Wind promedio_TempC
##   <int>         <dbl>         <dbl>         <dbl>         <dbl>
## 1     8             60           173.           8.86           28.7
## 2     7            59.1          216.           8.52           28.8
## 3     9            31.4          168.          10.1           24.9
## 4     6            29.4          184.          12.2           25.7
## 5     5            24.1          182.          11.5           19.1
```

Ejercicio 4

Usa la base de datos `Orange`.

En este ejercicio debes usar la tubería para preparar los datos, pero luego debes calcular dos resultados diferentes.

Haz lo siguiente:

1. Conserva únicamente las columnas `Tree`, `age` y `circumference`.
2. Crea una columna llamada `crecimiento_relativo`, definida como:

$$\text{crecimiento_relativo} = \frac{\text{circumference}}{\text{age}}$$

3. Guarda el resultado en un objeto llamado `naranjos`.
4. Usando `naranjos`, calcula para cada árbol:
 - la edad mínima,
 - la edad máxima,
 - la circunferencia mínima,
 - la circunferencia máxima,
 - el promedio de `crecimiento_relativo`.
5. Ordena el resultado de mayor a menor según el promedio de `crecimiento_relativo`.
6. Luego, usando otra tubería, conserva únicamente las observaciones donde `age > 1000` y calcula la correlación entre `age` y `circumference`.

```
library(dplyr)

naranjos <- Orange %>%
  select(Tree, age, circumference) %>%
  mutate(crecimiento_relativo = circumference / age)

resultado_orange <- naranjos %>%

  group_by(Tree) %>%

  summarise(edad_minima = min(age),
            edad_maxima = max(age),
            circunferencia_minima = min(circumference),
            circunferencia_maxima = max(circumference),
            promedio_crecimiento_relativo =
              mean(crecimiento_relativo)) %>%

  arrange(desc(promedio_crecimiento_relativo))

resultado_orange

## # A tibble: 5 x 6
##   Tree edad_minima edad_maxima circunferencia_minima circunferencia_maxima
##   <ord>      <dbl>      <dbl>              <dbl>              <dbl>
## 1 4          118        1582                32                214
## 2 2          118        1582                33                203
## 3 5          118        1582                30                177
## 4 1          118        1582                30                145
## 5 3          118        1582                30                140
## # i 1 more variable: promedio_crecimiento_relativo <dbl>
```

```
correlacion_orange <- naranjos %>%
  filter(age > 1000) %>%
  summarise(correlacion = cor(age, circumference))
```

```
correlacion_orange
```

```
## correlacion  
## 1 0.5115735
```
